SID Pêche en Province Sud



De l'API à l'indicateur : construction d'un système d'information décisionnel

Master MIAGE · Gestion et entreposage des données

Élodie TRAN - Bastian CAZAUX - Anthony GASS - Maud GRANGER

Le contexte et l'objectif



Le besoin

Suivre la pêche côtière en Province Sud : qui pêche, avec quel navire, quelles espèces, à quel endroit et avec quelle rentabilité.



Le problème

Les données vivent dans un système de production, fait pour enregistrer des cartes et des campagnes, pas pour les analyser.



L'objectif

Transformer ces données brutes en indicateurs qu'un gestionnaire peut lire et comprendre.

Données anonymisées · API de la Province Sud · pêche côtière

Le plan : une chaîne en cinq briques



À chaque étape : ce que nous avons fait, et surtout pourquoi nous avons fait ces choix.

BESOIN

Le besoin d'abord : le SFD

20
indicateurs définis

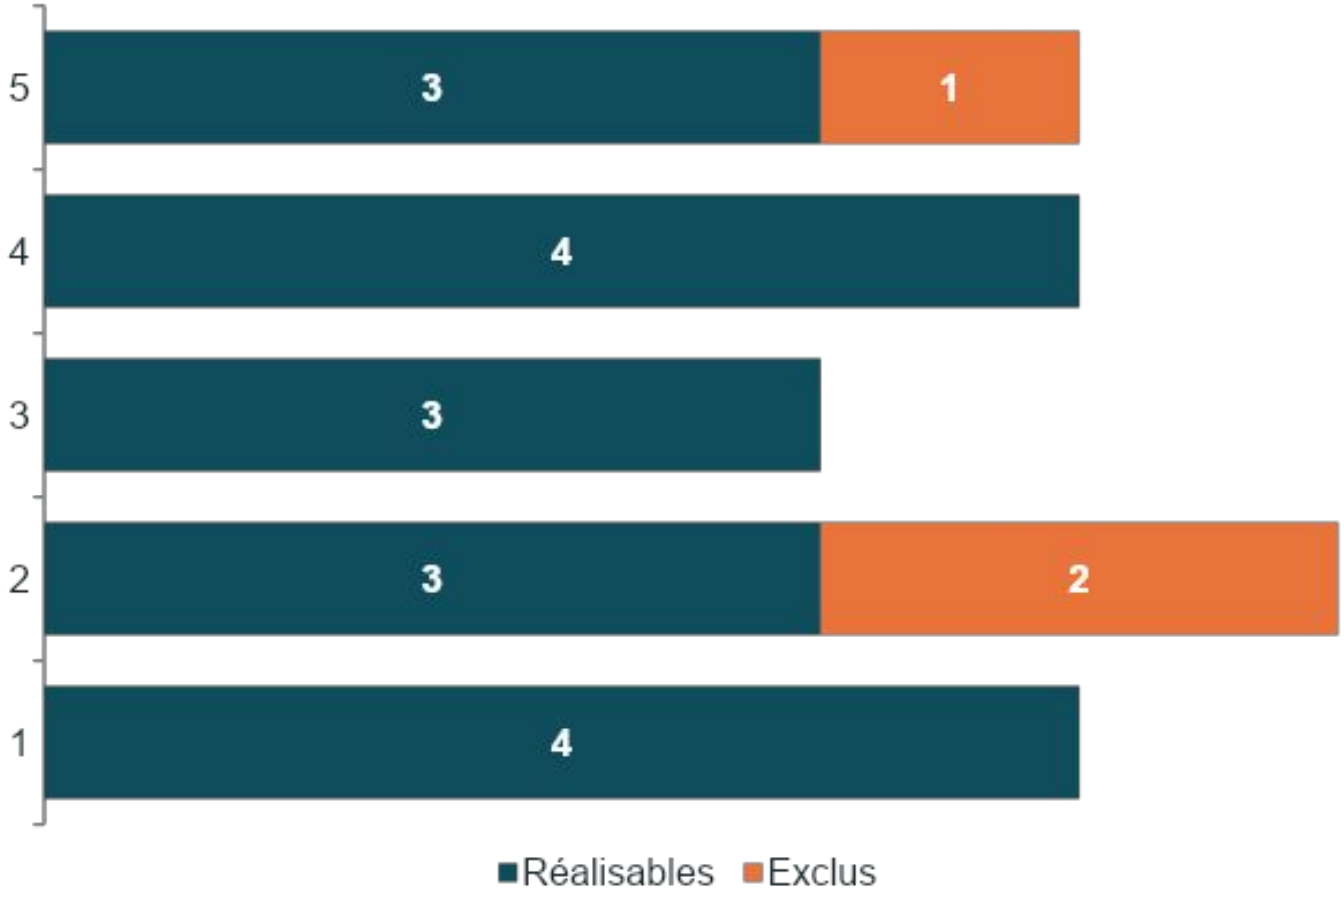
5
familles d'analyse

17
indicateurs réalisables

3
exclus, faute de lien fiable

Le SFD donne pour chaque indicateur : le grain, les axes d'analyse, les tables sources, la règle de gestion, le type de rendu.

Cinq familles, vingt indicateurs



Sociologique : qui sont les pêcheurs

Matérielle : la flotte de navires

Environnementale : ce qui est pêché

Activité : les sorties en mer

Économique : l'argent gagné et dépensé

BESOIN

Les 20 indicateurs, famille par famille

Sociologique 4 indicateurs	Matérielle 5 indicateurs	Environnementale 3 indicateurs	Activité 4 indicateurs	Économique 4 indicateurs
3.1.1 Pêcheurs actifs	**3.2.1** Nombre de navires	**3.3.1** Évolution des captures	**3.4.1** Nombre de campagnes	**3.5.1** Rentabilité par pêcheur
3.1.2 Évolution, âge, genre, commune	**3.2.2** Âge de la flotte	**3.3.2** Captures par espèce	**3.4.2** Durée d'une campagne	**3.5.2** Rentabilité par campagne
3.1.3 Expérience cumulée	**3.2.3** Frais d'entretien (exclu)	**3.3.3** Captures par zone	**3.4.3** Captures par campagne	**3.5.3** Évolution des coûts
3.1.4 Capitaines et patrons	**3.2.4** Motorisation		**3.4.4** Campagnes actives	**3.5.4** Rentabilité par navire (exclu)
	3.2.5 Navires par pêcheur (exclu)			

Fond orange : indicateur exclu, faute de lien fiable avec le navire.

BESOIN

Trois indicateurs exclus, volontairement

SFD	Indicateur	Pourquoi il est exclu
3.2.3	Frais d'entretien de la flotte	Aucun lien entre les frais et le navire
3.2.5	Nombre de navires par pêcheur	Aucune clé de liaison pêcheur ↔ navire
3.5.4	Rentabilité par navire	Aucune relation campagne ↔ navire



BESOIN

Des règles de gestion écrites à l'avance

Pêcheur actif

Sa dernière carte est de l'année de référence, sans statut de cessation d'activité ni de vente.

Campagne

Rattachée à sa date de début. Active si début ≤ date de référence ≤ fin.

Âge d'un navire

Année de référence moins année de construction. Année absente : exclu du calcul.

Montants

Repris de la source, jamais recalculés. Un écart est signalé, pas corrigé.

L'architecture d'ensemble



Une seule base, peche_nc, avec des schémas séparés : env_mer (ODS), dwh et dtm_performance_campagnes (DTM).

Chaque couche lit la précédente. La page lit le DTM (activité, économique) et le DWH (le reste).

Pourquoi plusieurs couches ?

Traçabilité

À chaque étape, on sait d'où vient un chiffre.

Rejouabilité

On refait une étape sans refaire les précédentes.

Lisibilité

Chaque brique a un seul rôle.

Réutilisation

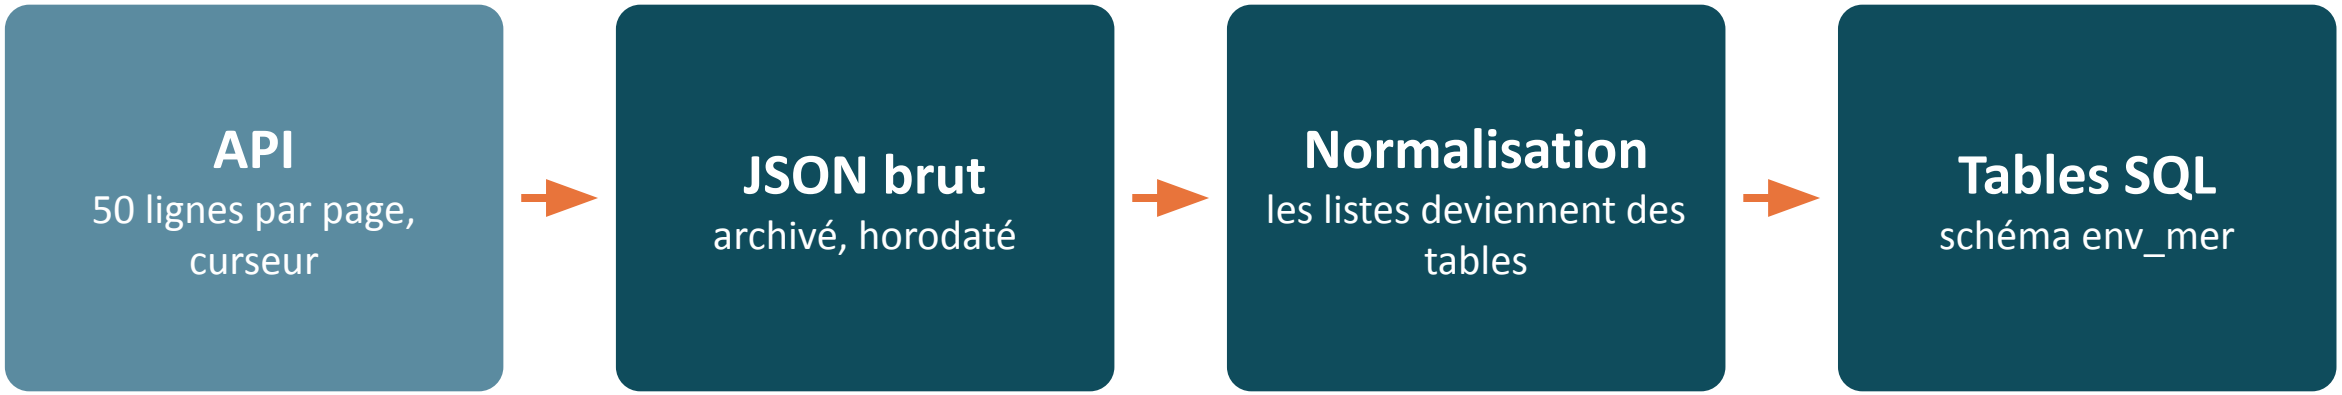
Un même DWH peut alimenter d'autres DTM.

Ordre de lancement : toujours ODS, puis DWH, puis DTM, avec une seule commande : python main.py.

La récupération des données - API Province Sud

Point d'accès	Contenu
pecheur_anonymise	Cartes de pêche, avec capitaine et patron
navire_peche_anonymise	Navires et leurs moteurs
campagne_peche	Sorties en mer et leurs frais
capture_peche	Captures, espèces et zones
carroyage_peche	Découpage de la mer en zones

L'ODS : de l'API aux tables SQL



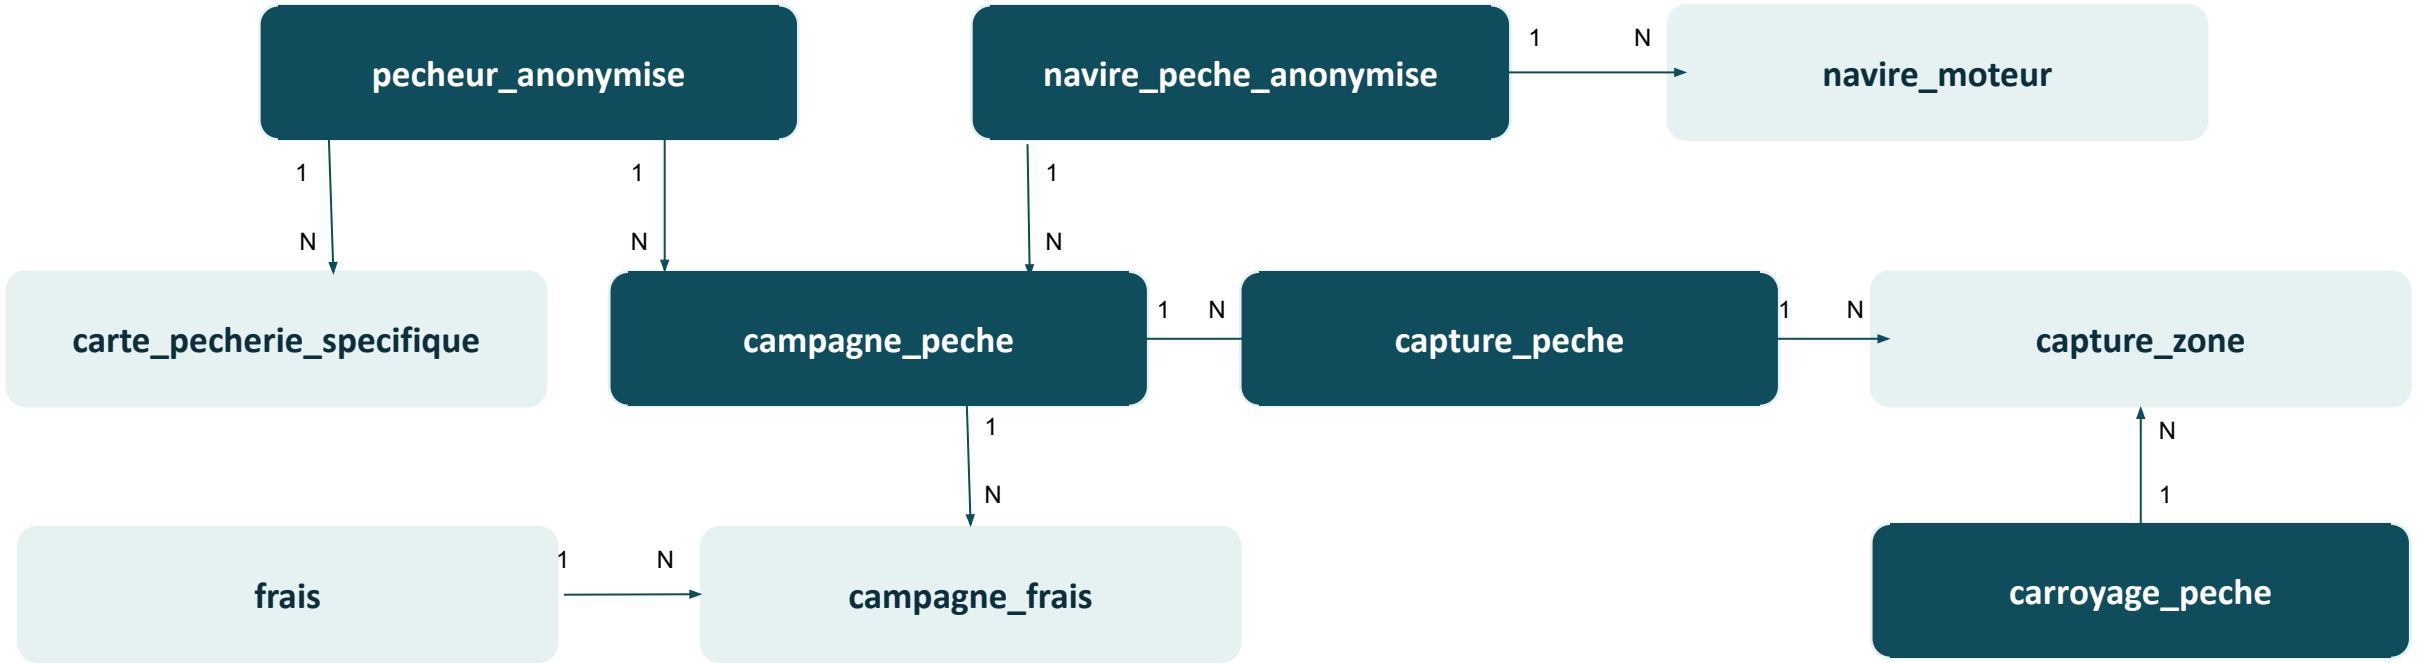
Principe : aucune interprétation. L'ODS est une copie fidèle du modèle de donnée originel.
Fidèle ne veut pas dire propre : les contrôles viennent après.

La normalisation : éclater les listes

Un navire	contient une liste de moteurs	**navire_moteur**
Une campagne	contient une liste de frais	**campagne_frais**
Une capture	contient une liste de zones	**capture_zone**
Une carte	contient une liste de pêcheries	**carte_pecherie_specifique**

Plus une table de référence des frais : 13 types (carburant, glace, appâts, entretien du bateau et du moteur…).

Le schéma de l'ODS : dix tables reliées



Les clés étrangères garantissent les liens dès l'ODS : une campagne pointe vers sa carte, une capture vers sa campagne, un moteur vers son navire.

Choix techniques

Pagination par curseur

Le client suit le curseur fourni par l'API jusqu'à la dernière page, avec des relances automatiques en cas d'erreur réseau.

JSON brut archivé

Tout est téléchargé avant de toucher à la base : si le réseau tombe, l'ODS reste intact. Cinq archives horodatées sont conservées.

SQL Server ou PostgreSQL

Un réglage de configuration choisit le moteur. Clé d'API et connexion restent hors du code.

Rechargement et tests

Tables recréées à chaque lancement.
Tests automatiques (pytest), lancés par la CI GitHub à chaque modification du code.

La qualité : ce que nous avons trouvé

Données incomplètes

Année de construction des navires parfois absente, informations démographiques partiellement renseignées.

Valeurs à normaliser

Année de construction fournie en texte, variantes d’écriture pour certains types de carte.

Identifiants

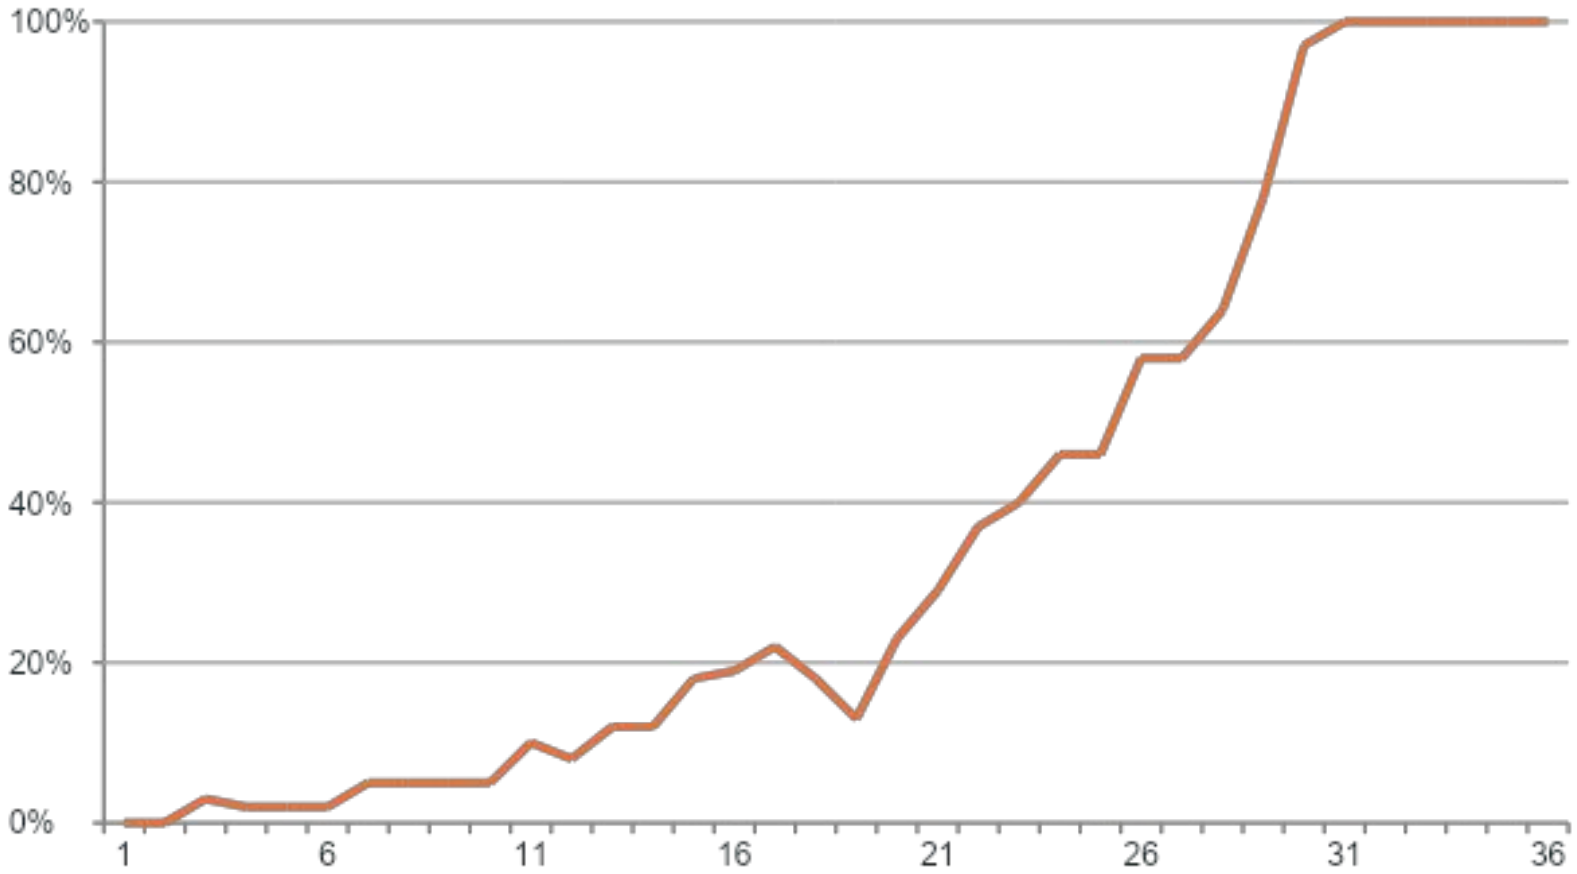
Patron pêcheur progressivement mieux renseigné selon les années et une même personne peut posséder plusieurs cartes.

Relations incomplètes

Zones ↔ carroyages mal alimentés, aucun lien fiable entre une campagne et son navire.

Le patron apparaît peu à peu

Part des cartes avec un patron pêcheur renseigné, par année



100 %

depuis 2021

58 %

en 2016

3 %

en 1993 (2 cartes sur 75)

QUALITÉ

Ne jamais corriger en devinant

Détecter
des requêtes de contrôle

→

Signaler
les anomalies détectées

→

Neutraliser
NULL / membre “Inconnu”

Durée de campagne NULL si la fin précède le début

Date hors calendrier : rattachée à la ligne « Inconnu »

Longueur, jauge ou marées négatives : NULL

Montants jamais recalculés : l'écart est signalé

DWH

Le DWH : 17 tables pour analyser

4

faits : ce qu'on mesure (un montant, un poids, un nombre)

11

dimensions : les axes selon lesquels on regarde

2

ponts : les relations many-to-many



Comme un tableau croisé : les faits sont les chiffres au centre, les dimensions sont les titres des lignes et des colonnes.

Quatre faits, quatre grains d'analyse

FAIT_CARTE

1 ligne = 1 carte
Recette • dépense • bénéfice • marées

FAIT_CAMPAGNE

1 ligne = 1 campagne
Durée • recette • dépense • bénéfice

FAIT_CAPTURE

1 ligne = 1 capture
Quantité • poids • valeur XPF

FAIT_FRAIS

1 ligne = 1 poste
Nature • montant



Chaque table de faits possède son propre grain : les mesures restent ainsi au bon niveau de détail et ne sont pas comptées plusieurs fois.

Pourquoi séparer les grains ?

Une seule table :

Carte A — bénéfice 1 000

- Capture 1 -> 1 000
- Capture 2 -> 1 000
- Capture 3 -> 1 000

Somme : 3 000 ✗

Avec les Faits Séparés

FAIT_CARTE

Carte A -> 1 000

FAIT_CAPTURE

Capture 1
Capture 2
Capture 3

Somme : 1 000 ✓



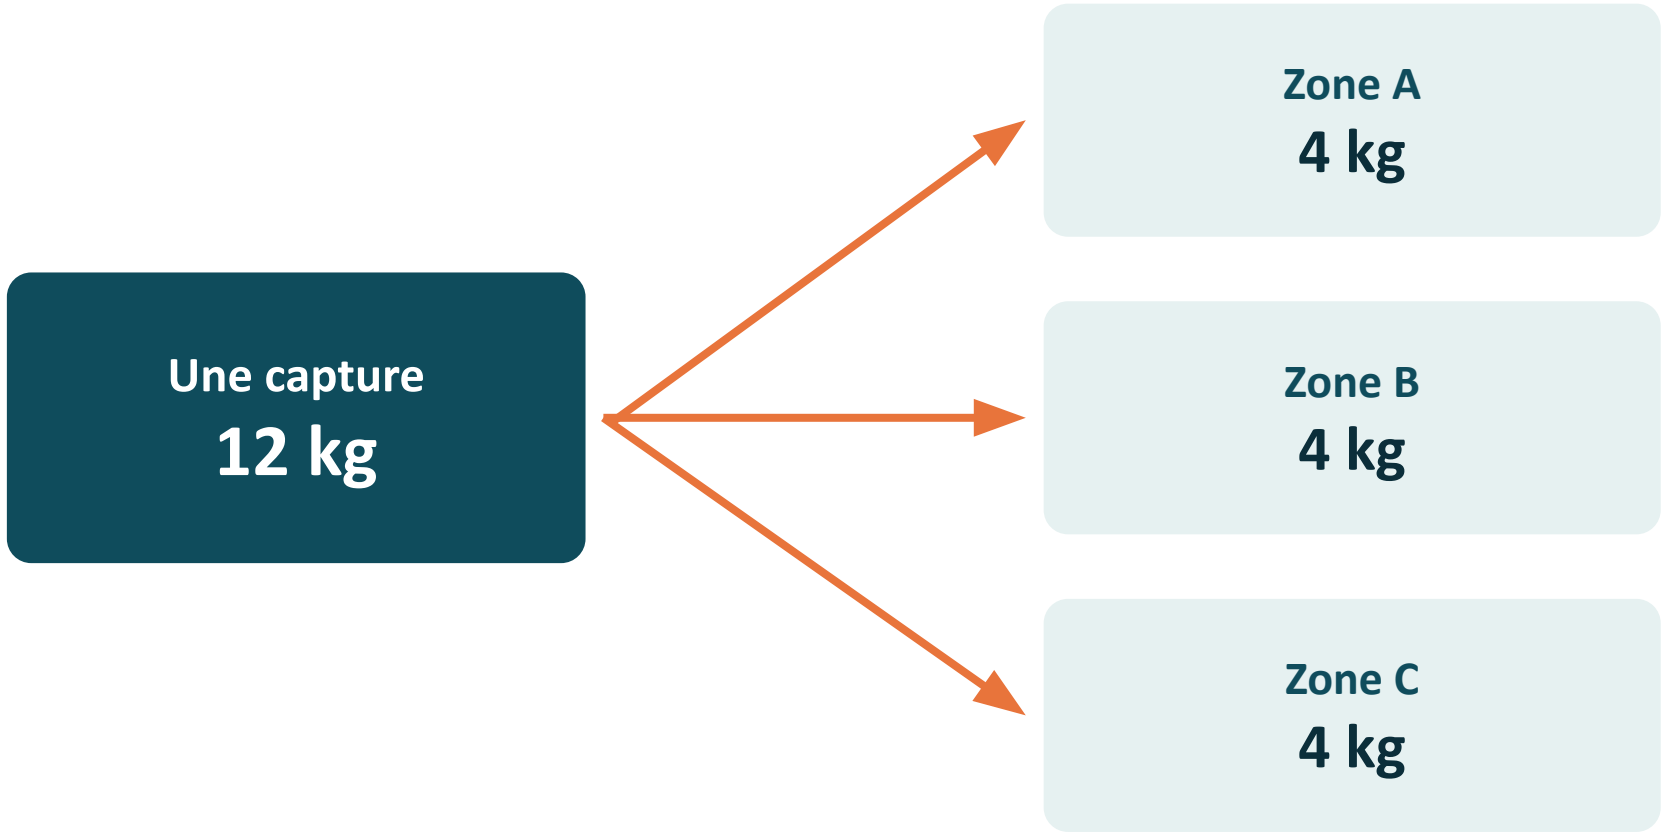
Une mesure reste dans la table correspondant à son grain pour éviter sa duplication.

Les 11 dimensions : nos axes d'analyse

Temps	DIM_TEMPS			
Personnes et lieux	DIM_PERSONNE	DIM_COMMUNE	DIM_ZONE_PECHE	DIM_CARROYAGE
Matériel	DIM_NAVIRE	DIM_MOTEUR		
Captures	DIM_ESPECE	DIM_TECHNIQUE		
Réglementation	DIM_CARTE	DIM_PECHERIE		

Calendrier généré de 1990 à 2050, jours sans activité inclus · une seule ligne par personne (capitaines et patrons fusionnés)

Les ponts : ne pas compter deux fois



Le facteur

1 ÷ nombre de zones, stocké dans le pont.

Sans lui

12 kg comptés dans chacune des 3 zones : 36 kg ✗

Une capture touche jusqu'à 6 zones. Un second pont relie les cartes aux pêcheries qu'elles autorisent.

Clés de substitution et « Inconnu »

Clé de substitution

Chaque dimension a sa propre clé numérique, indépendante des identifiants de la source.

Membre « Inconnu »

Chaque dimension contient une ligne de clé −1 : aucune clé vide, aucune jointure ne perd de ligne.

Le piège rencontré : en SQL, « vide = vide » est faux. Les 1 086 captures sans technique seraient tombées dans « Inconnu » à tort. Nos jointures reconnaissent les vides, et un contrôle automatique le vérifie.

Les choix assumés du DWH

Clés primaires, pas de clés étrangères

Les liens sont vérifiés par des requêtes de contrôle, pas par des contraintes.

Navire indicatif

Le navire des faits vient de la carte : le navire autorisé, pas forcément celui de la campagne.

Initialisation seulement

Reconstruction complète à chaque lancement, sans historique. L'incrémental prévu au SFD reste à écrire.

Le DTM : lire sans jointures

Dans le DWH

- **FAIT_CAMPAGNE**
- + DIM_CARTE
- + FAIT_CARTE (le capitaine)
- + DIM_PERSONNE
- + DIM_COMMUNE
- + DIM_TEMPS (début)
- + DIM_TEMPS (fin)



Dans le DTM

Une seule table à plat : la restitution la lit directement.

DTM_PERFORMANCE_CAMPAGNE

Un DTM est un sous-ensemble du DWH, limité à un sujet : ici, la performance des campagnes.

Trois tables pour les campagnes

Table du DTM	Une ligne =	Indicateurs
DTM_PERFORMANCE_CAMPAGNE	une campagne (environ 63 900)	3.4.1, 3.4.2, 3.4.4, 3.5.1, 3.5.2
DTM_CAPTURE_CAMPAGNE	une campagne et une espèce	3.4.3
DTM_FRAIS_CAMPAGNE	un poste de dépense d'une campagne	3.5.3



Les familles sociologique, matérielle et environnementale n'ont pas de DTM : le périmètre de la version 1 se limite à la performance des campagnes. Elles interrogent directement le DWH.

Trois précautions dans le DTM

Navire

Aucun attribut navire dans la table des campagnes (3.5.4 exclu). Dans les frais, les axes navire sont gardés mais indicatifs.

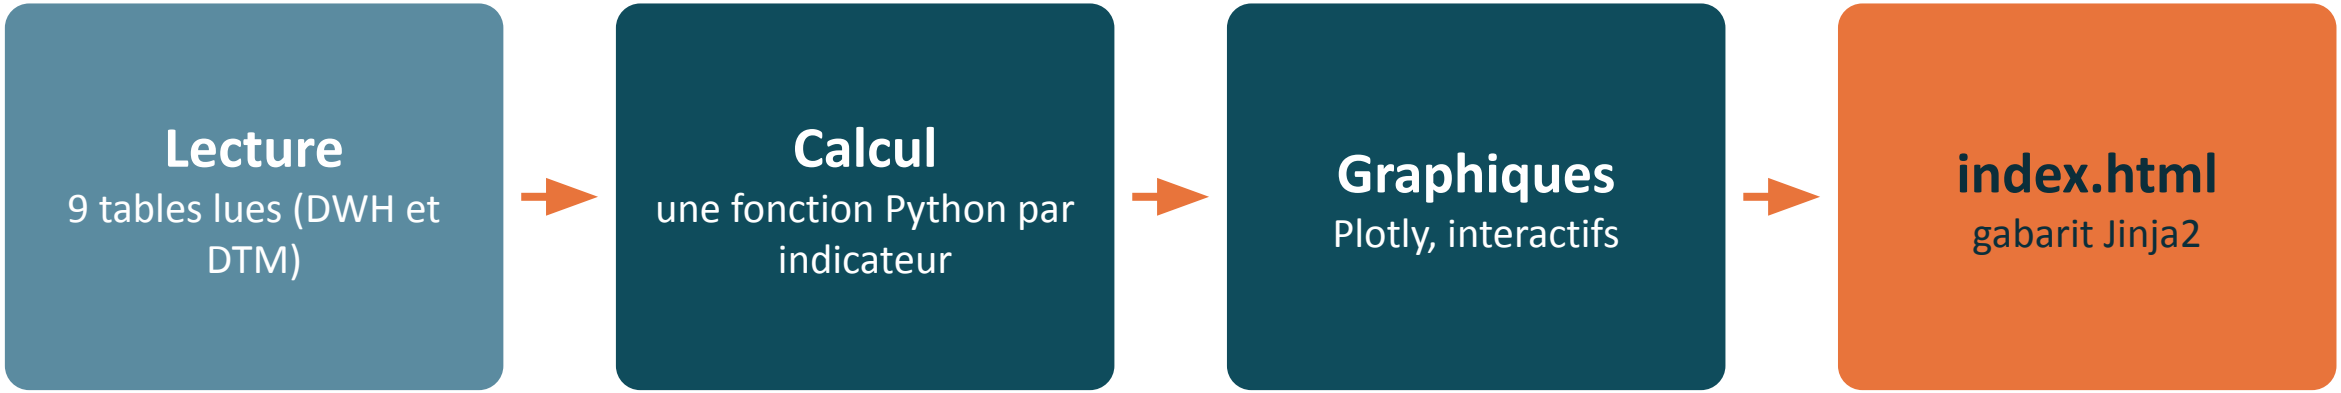
Zone de pêche

Absente des frais : une campagne touche plusieurs zones, les lignes seraient dupliquées et les sommes fausses.

Frais ≠ dépense

La somme des frais n'égale pas la dépense d'une campagne : les salaires n'y sont pas. Ce n'est pas une anomalie.

La restitution : du script à la page web



La date de référence est fixée à la génération (aujourd'hui par défaut). La page offre des chiffres clés comparés à l'an dernier, des graphiques interactifs, un mode jour et nuit et l'export CSV des campagnes actives.

Chaque indicateur est défini deux fois

DAX, la définition de référence

```
Nb campagnes =
DISTINCTCOUNT(
  DTM_PERFORMANCE_CAMPAGNE[campagne_id]
)
```

=

Python (pandas), la fonction équivalente

```
# 3.4.1 même calcul, ventilé par mois
c.groupby("Mois")["campagne_id"]
  .nunique()
```

Une formule de référence, une fonction Python qui la reproduit : des tests automatiques vérifient les calculs.
Une fiche de consignes décrit les 17 indicateurs.

Trois exemples d'indicateurs



Pêcheurs actifs

Pour chaque capitaine, sa dernière carte à la date de référence. Actif si elle est de l'année de référence, sans statut de cessation ni de vente. On compte les capitaines distincts.



Campagnes actives

Début ≤ date de référence ≤ fin. La page affiche une liste exportable : capitaine, durée, jours en mer et de pêche.



Rentabilité annuelle

Recettes, dépenses et bénéfice cumulés par pêcheur et par année. Pas de taux de rentabilité tant que le métier n'en a pas fixé la formule.

Ce que la page affiche avec prudence

Patron avant 2021

Souvent vide : la catégorie « Non renseigné » est affichée.

Navire indicatif

Navire autorisé sur la carte, pas forcément celui de la campagne.

Valeur en XPF

Sous réserve de validation de sa cohérence. Quantité en nombre d'individus : souvent 0.

Zones de pêche

Aucun contour dans le DWH : histogramme par zone, pas de carte. Zone renseignée pour environ 14 % des captures.

CONCLUSION

Le bilan en quatre chiffres

10
tables dans l'ODS

17
tables dans le DWH

3
tables dans le DTM

17 / 20
indicateurs réalisés

Une chaîne complète : API, ODS, DWH, DTM, page d'indicateurs. Les trois indicateurs restants ont été exclus faute de lien fiable dans les sources.

Limites connues et prolongements

Limites connues

- Pas d'historique : les scripts initialisent
- Pas de carte : un histogramme par zone
- Page web : un instantané, pas du direct

Prolongements

- Historisation et chargement incrémental
- D'autres DTM : pêcheurs, flotte, captures
- Contours pour une vraie carte, planification du pipeline
- Lien navire ↔ campagne : débloquer 3 indicateurs

CONCLUSION

Trois idées à retenir

1. On part du besoin, pas des données
2. Chaque couche a un rôle et un script rejouable
3. Moins de chiffres, mais des chiffres défendables

Merci de votre attention !